

ANALISIS TREN DAN POLA POPULARITAS ARTIKEL WIKIPEDIA BERDASARKAN DATA PAGEVIEWS (2016–2026)

Grafik Tren Artikel
Wikipedia



Analisis Karakteristik
Big Data 8V



NAMA KELOMPOK

GACHA



PURI KHAIRUNISA R
(24083010094)

VINA NUR AINI P
(24083010096)

SELVY DWI YULITA S
(24083010095)

KIKY MAUDRY N
(24083010110)




LATAR BELAKANG

Perkembangan informasi digital menyebabkan jumlah artikel yang diakses di internet terus meningkat setiap hari. Data kunjungan (pageviews) yang dihasilkan sangat besar dan dinamis, sehingga sulit untuk mengidentifikasi pola serta tren popularitas suatu artikel secara cepat.

Wikipedia sebagai salah satu sumber informasi terbesar di dunia menyediakan data pageviews yang dapat dimanfaatkan untuk menganalisis perilaku pengguna. Oleh karena itu, dilakukan analisis data pageviews Wikipedia untuk mengidentifikasi tren popularitas artikel, artikel yang paling diminati, serta pola lonjakan kunjungan yang berkaitan dengan peristiwa tertentu.

PENCAPAIAN





TUJUAN ANALISIS


**MENGIDENTIFIKASI ARTIKEL
POPULER BERDASARKAN
JUMLAH KUNJUNGAN
(VIEWS)**



**MENDETEKSI LONJAKAN (SPIKE)
POPULARITAS PADA ARTIKEL
TERTENTU**

**MENGANALISIS TREN DAN
POLA AKSES ARTIKEL
BERDASARKAN WAKTU**

**MEMAHAMI PERILAKU
PENGGUNA BERDASARKAN
DATA PAGEVIEWS**



DATASET

GACHA

Sumber Data

Wikimedia Pageviews API

wikimedia.org (Wikimedia Foundation)

Data yang diambil

- Article
- Timestamp
- Views

Jumlah data

- Wikipedia En : 64,944,259
- Wikipedia Id : 60,083,446


Rentang tahun artikel

- Terlama : 01 Agustus 2016
- Terbaru : 31 Januari 2026



	article	timestamp	views
0	San_Junipero	2016072700	7
1	San_Junipero	2016072800	28
2	San_Junipero	2016072900	7
3	San_Junipero	2016073000	15
4	San_Junipero	2016073100	10
5	San_Junipero	2016080100	21
6	San_Junipero	2016080200	20
7	San_Junipero	2016080300	15
8	San_Junipero	2016080400	12
9	San_Junipero	2016080500	16

VOLUME




Data UTS (EN) : 64,944,259

Data EAS (EN + ID) : 125,027,705




Penambahan data : 60,083,446

```
*** === VOLUME ===
Jumlah baris : 125,027,705
Jumlah kolom : 3
Ukuran file : 3.96 GB
```



Dataset memiliki sekitar 125 juta baris data dengan 3 kolom utama dan penggunaan memori mencapai 3.96 GB. Jumlah data yang besar ini menunjukkan bahwa dataset termasuk dalam kategori big data dari aspek volume







```
Jam unik:  
[0]  
Rata-rata interval:  
1 days 00:00:00
```

Dari timestamp, terlihat bahwa data diperbarui setiap hari dengan interval yang konsisten (± 1 hari), dan seluruh data tercatat pada jam yang sama (00:00). Ini menunjukkan bahwa data masuk secara rutin dan terjadwal.

Selain itu, dari grafik terlihat bahwa jumlah views terus berubah dari waktu ke waktu. Ada pola naik turun dan beberapa lonjakan pada periode tertentu. Gabungan antara pembaruan data yang rutin dan perubahan nilai yang terus terjadi menunjukkan bahwa data memiliki velocity tinggi.



VARIETY



	Kolom	Tipe Data
0	article	String
1	timestamp	Int64
2	views	Int64



Aspek Variety dianalisis melalui struktur atribut yang dimiliki dataset. Pada fase UTS, dataset memiliki 6 kolom yaitu article, timestamp, views, year, month, dan day. Pada fase EAS, kolom year, month, dan day dihapus karena merupakan kolom turunan (derived) dari timestamp sehingga bersifat redundan. Hasilnya, dataset disederhanakan menjadi 3 kolom utama (article, timestamp, views).



VERACITY




```
Data awal          : 125027705  
Duplikat sebelum  : 39701628  
Missing sebelum   : 7674
```

=== RINGKASAN DATA ===


```
Data setelah preprocessing : 106,288,445  
Missing sesudah           : 0  
Duplikat sesudah          : 0
```

Dataset awal memiliki 125.027.705 baris dengan ditemukan 39.701.628 data duplikat dan 7.674 missing value. Setelah proses preprocessing (penghapusan duplikat dan missing value), jumlah data bersih menjadi 106.288.445 baris






Value dianalisis berdasarkan frekuensi kemunculan artikel pada data. Grafik menunjukkan 10 artikel yang paling sering muncul dalam dataset, yaitu Washington Capitals, new girl, Jury Nullification, dan artikel lainnya. Frekuensi kemunculan yang relatif seragam (sekitar 3.800–3.900 record) menunjukkan bahwa distribusi data cukup merata dan tidak didominasi oleh satu artikel tertentu. Hal ini mengindikasikan bahwa dataset memiliki nilai informasi yang beragam dan dapat digunakan untuk menganalisis berbagai topik yang diminati pengguna Wikipedia.






VALIDITY


Proporsi Data Valid vs Tidak Valid




Berdasarkan hasil validasi data, seluruh data yang dianalisis dinyatakan valid. Grafik menunjukkan bahwa proporsi data valid mencapai 100%, sedangkan data tidak valid sebesar 0%. Hasil ini mengindikasikan bahwa proses pengumpulan, pembersihan, dan verifikasi data telah dilakukan dengan baik sehingga tidak ditemukan data yang bermasalah atau perlu dieliminasi. Dengan demikian, seluruh data dapat digunakan pada tahap analisis berikutnya tanpa adanya pengurangan sampel akibat ketidakvalidan data.




VARIABILITY




Aspek Variability menunjukkan adanya fluktuasi jumlah views Wikipedia dari waktu ke waktu. Perubahan ini mencerminkan dinamika minat pengguna terhadap berbagai topik yang dipengaruhi oleh tren, peristiwa aktual, maupun isu yang sedang populer. Garis rolling mean 7 hari digunakan untuk memperjelas pola tren jangka pendek dan mengurangi noise pada data harian.










VARIABILITY




Grafik rata-rata views per bulan menunjukkan adanya variasi (variability) pola akses Wikipedia berdasarkan waktu bulanan. Terlihat bahwa jumlah views tertinggi terjadi pada bulan Februari, sedangkan bulan-bulan seperti November dan Agustus memiliki rata-rata views yang lebih rendah. Perbedaan antarbulan tidak terlalu ekstrem, namun tetap menunjukkan adanya fluktuasi permintaan pengguna yang dapat dipengaruhi oleh faktor musiman, tren pencarian, atau aktivitas pengguna. Dalam karakteristik big data, hal ini menunjukkan adanya perubahan pola data berdasarkan dimensi waktu yang perlu diperhatikan saat melakukan analisis tren atau prediksi.








Heatmap ini menunjukkan variasi pola views artikel berdasarkan waktu dan konten. Perbedaan intensitas warna menggambarkan perubahan jumlah views, di mana beberapa artikel mengalami peningkatan signifikan pada tahun tertentu (misalnya `Sonic_the_Hedgehog_3` pada 2024 dan `Attack_on_Titan` pada 2021). Visualisasi ini membantu melihat pola distribusi data secara lebih jelas, sehingga menunjukkan karakteristik visualization dalam big data untuk memahami tren, perbandingan, serta perubahan popularitas antar artikel dari waktu ke waktu. Penggunaan heatmap mempermudah identifikasi pola dan perbandingan popularitas antar artikel secara cepat dan intuitif.




Top 10 Artikel Paling Populer




Terdapat variasi popularitas artikel berdasarkan jumlah views. Beberapa artikel memiliki jumlah kunjungan jauh lebih tinggi dibanding artikel lainnya, yang menunjukkan distribusi data tidak merata. Dalam karakteristik big data, hal ini menggambarkan adanya perbedaan pola minat pengguna terhadap suatu konten.

Top 10 Artikel Paling Sering Spike




Adanya lonjakan views pada artikel tertentu. Artikel dengan jumlah spike tinggi mengalami peningkatan akses secara tiba-tiba lebih sering dibanding artikel lain, yang menunjukkan adanya perubahan perilaku pengguna atau tren sesaat. Hal ini mencerminkan karakteristik variasi dan ketidakstabilan data (variability) dalam data besar.

ANALISIS LANJUTAN



Lonjakan page views umumnya terjadi saat peristiwa politik besar, seperti Pemilu 2024, pengumuman hasil pemilu, dan pelantikan Presiden/Wakil Presiden pada Oktober 2024. Prabowo Subianto menjadi tokoh dengan perhatian publik tertinggi pada periode tersebut.



Donald Trump dan Prabowo Subianto sama-sama mengalami peningkatan page views pada tahun-tahun politik penting. Donald Trump mencapai puncak pada 2016 dan 2020, sedangkan Prabowo mencapai puncak pada 2024 setelah memenangkan Pilpres Indonesia.




KESIMPULAN



Dari hasil analisis, dapat disimpulkan bahwa data pageviews Wikipedia memiliki karakteristik Big Data yang lengkap dan kualitas data yang baik. Analisis menunjukkan bahwa popularitas artikel terus berubah mengikuti tren dan peristiwa yang terjadi di masyarakat. Melalui visualisasi dan analisis data, kita dapat memahami pola minat pengguna, mendeteksi lonjakan popularitas artikel, serta memanfaatkan informasi tersebut sebagai dasar pengambilan keputusan berbasis data.

PENCAPAIAN



THANK YOU

